正規表現の脆弱性

ReDoS 攻撃

を簡単に説明する回

xryuseix

@ryusei_ishika

1回生が入ったので，自己紹介

- 名前：石川琉聖(ID: xryuseix)
- 三回 情理 SNコースです
- セキュリティとアルゴリズムをやります
- いろんなイベントに出没します
- RiST元副団体長, RiPPro元団体長です
- C++とPythonをよく書きます

Event

年	内容
2019	セキュリティ・キャンプ全国大会2019 集中開発コース 暗号化通信ゼミ
2020-2021	若手セキュリティイノベーター育成プログラム SecHack365 研究駆動コース
2020	AVTOKYO 2020 Talks 情報通信システムセキュリティ研究会（ICSS） ▼ 研究テーマ ↓これICSS論文賞いただきました🎉 • 「仮想背景を使用したリモート会議映像における秘匿された背景の再構築手法」 ○辻知希，石川琉聖（立命館大）・衛藤将史（NICT）・服部祐一（セキュアサイクル）・井上博之（広島市大） • 「プログラミングコンテストにおけるソースコードの盗作検知手法の実装と評価」 ○石川琉聖（立命館大）・服部祐一（セキュアサイクル）・井上博之（広島市大）・猪俣敦夫（阪大）
2021	ICPC アジア地区横浜大会

Media

年	内容
2021	サイバーセキュリティII 第２回 情報セキュリティ教育と人材育成 BS231ch

Hack

年	内容
2020-	IPA 脆弱性関連情報届出受理 42件 ▶ 取得番号一覧

https://xryuseix.github.io/

ここからが本題です

- CTF の問題をプレゼント🎉

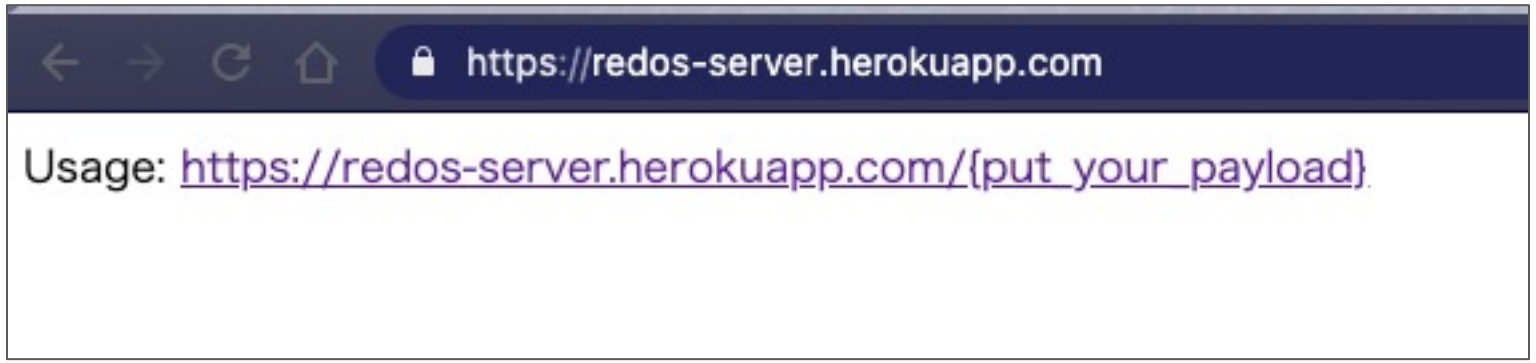

https://redos-server.herokuapp.com/

(開発ソースコード: https://github.com/xryuseix/ReDoS_server)

正規表現とは

- 文字列の集合を一つの文字列で表現する方法
- 言語によらず基本的には一緒

a から始まって z で終わる 3 桁の文字列

```
1. a.z
```

a から始まって z で終わる 2 桁以上の文字列

```
1. a.*z
```

4 桁以上の半角数字

```
1. \d{4,}
```

section. 3

使用頻度の高い正規表現式

Email アドレス (RFC準拠ではない)

```
^\w+([-+.]\w+)*@\w+([-.]\w+)*\.\w+([-.]\w+)*$
```

URL

```
^https?://([\w-]+\.)+[\w-]+(/[\w-./?%&=]*)?$
```

ドメイン名

```
^[a-zA-Z0-9][a-zA-Z0-9-]{1,61}[a-zA-Z0-9]\.[a-zA-Z-]{2,}$
```

固定電話番号

```
^0\d(-\d{4}|\d-\d{3}|\d\d-\d\d|\d{3}-\d)-\d{4}$
```

携帯電話番号

```
^0[789]0-\d{4}-\d{4}$
```

IP 電話番号

```
^050-\d{4}-\d{4}$
```

フリーダイヤル

```
^(0120|0800)-\d{3}-\d{3}$
```

日付 (YYYY-MM-DD形式)

```
^\d{4}-\d\d-\d\d$
```

郵便番号

```
^\d{3}-\d{4}$
```

https://murashun.jp/article/programming/regular-expression.html

正規表現はどう使うのか

- 基本的にできること
  - 大量の文字から特定の文字列を探す
    - “This is a pen.”の中に”pen”があるかまた何文字目にあるか
  - 文字列が正しい形式か判定する
    - 電話番号に0-0-0-0みたいなものを入力されないように
    - 入力に変な文字(制御文字など)を入力されないように
- ↑を用いてすること
  - 文字列の置換
    - “This is a pen. I like pen”の中にある”pen”を全て”apple”に変える
  - 文字列の分割
    - 文字列をスペース，カンマ，タブのいずれかで分割

正規表現はどう使うのか

- 基本的にできること**(Python re モジュール)**
  - 大量の文字から特定の文字列を探す **(re.search)**
    - “This is a pen.”の中に”pen”があるかまた何文字目にあるか
  - 文字列が正しい形式か判定する **(re.match)**
    - 電話番号に0-0-0-0みたいなものを入力されないように
    - 入力に変な文字(制御文字など)を入力されないように
- ↑を用いてすること
  - 文字列の置換 **(re.sub)**
    - “This is a pen. I like pen”の中にある”pen”を全て”apple”に変える
  - 文字列の分割 **(re.split)**
    - 文字列をスペース，カンマ，タブのいずれかで分割

実行の様子を確認する

- 正常１

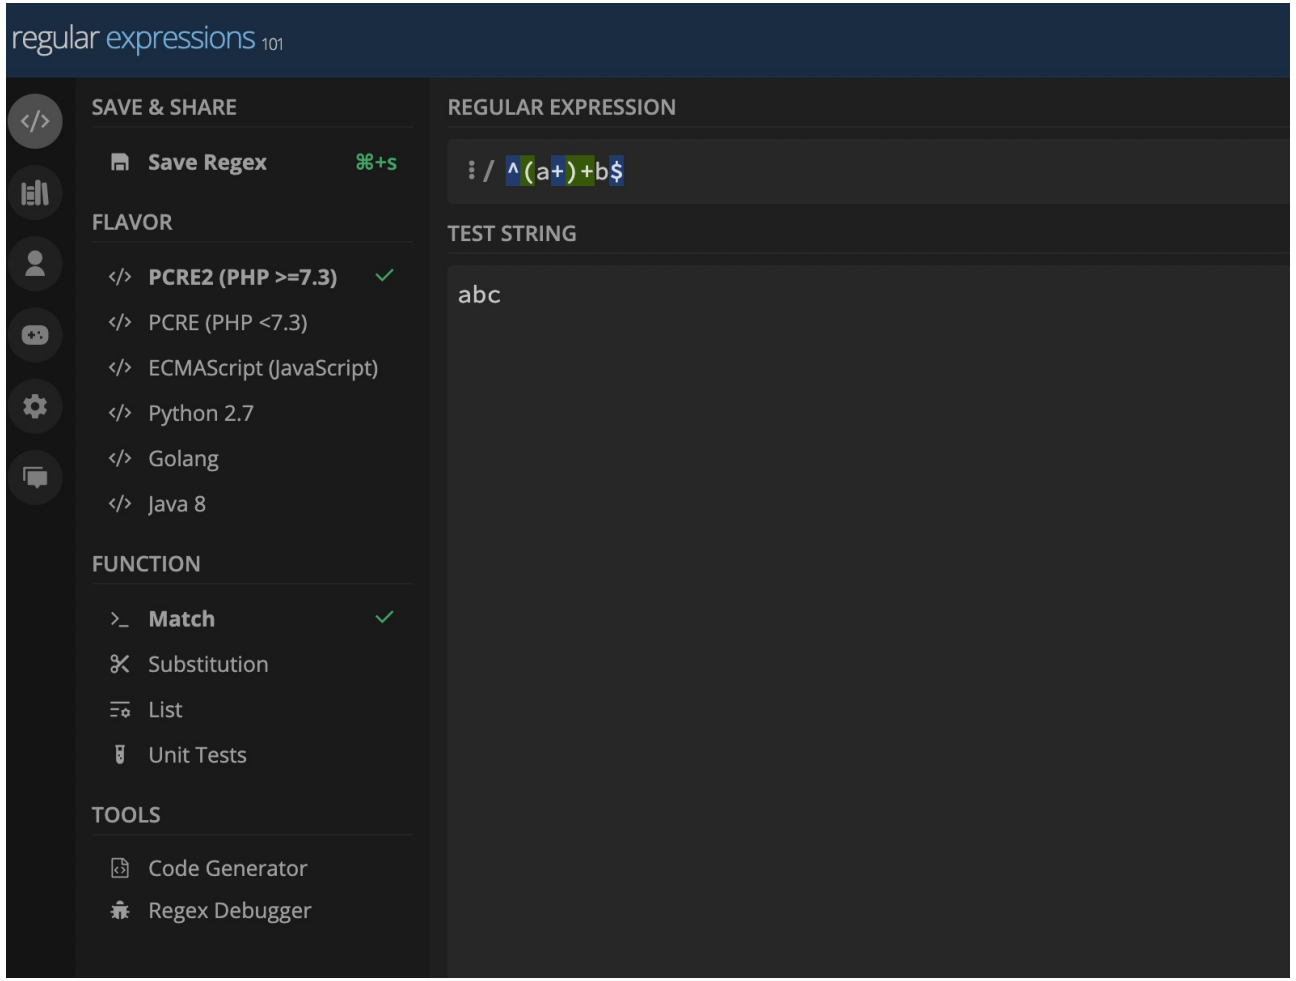

https://regex101.com/

実行の様子を確認する

- 正常１

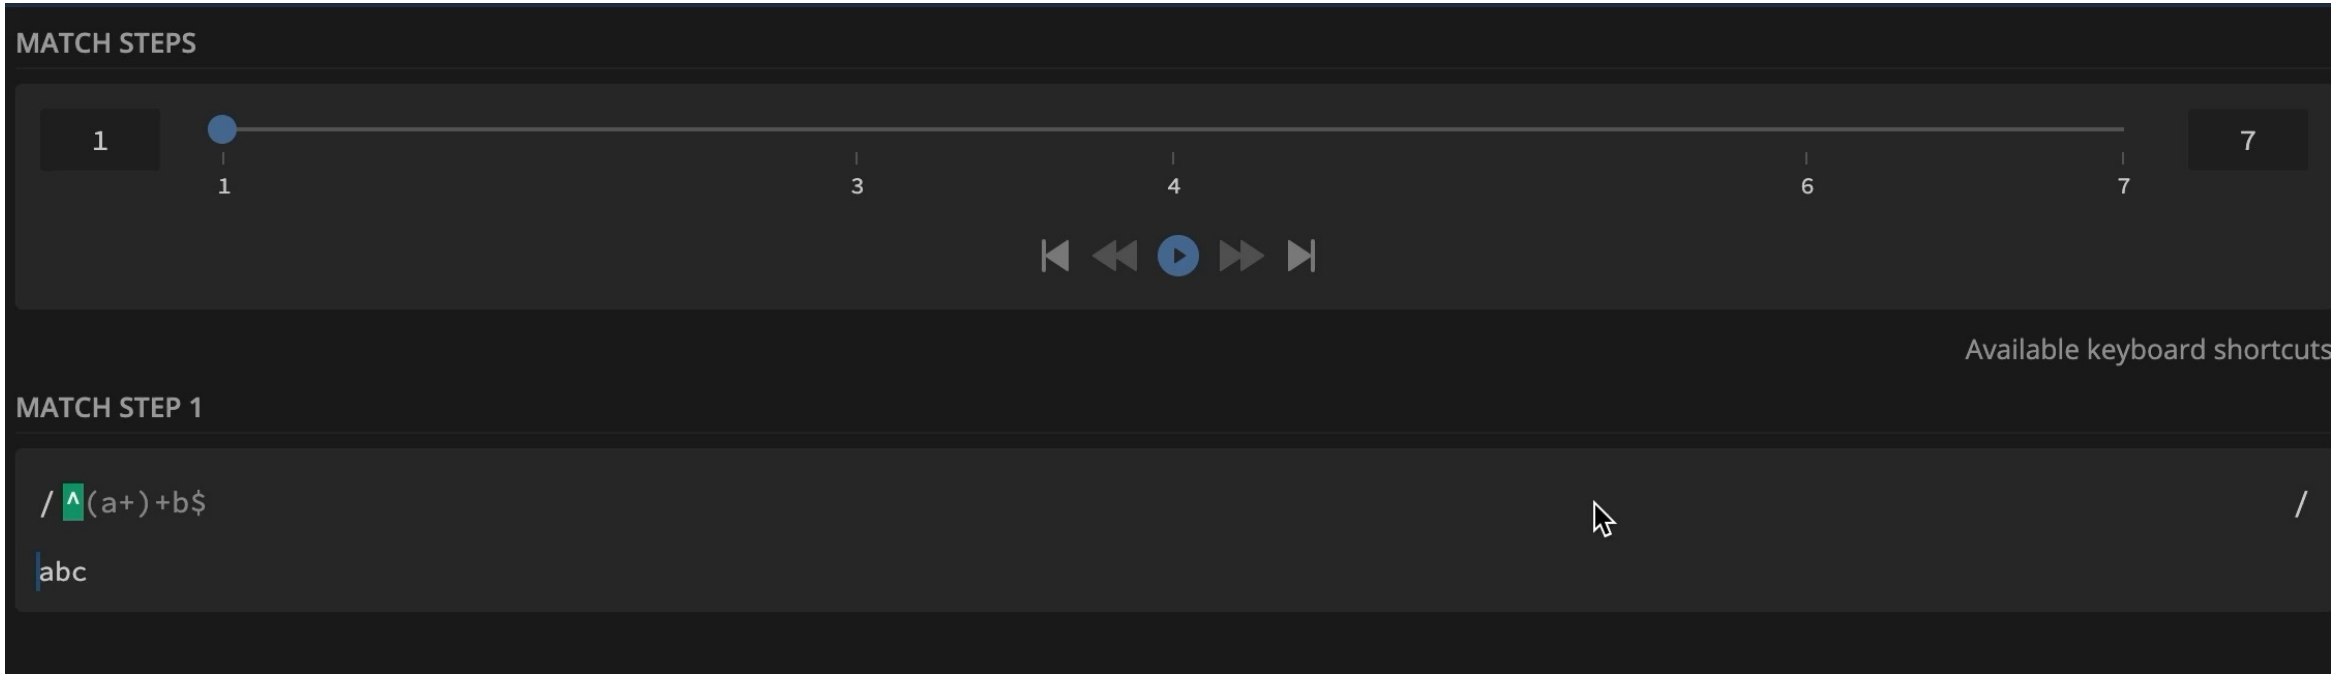

https://regex101.com/

実行の様子を確認する

- 正常2

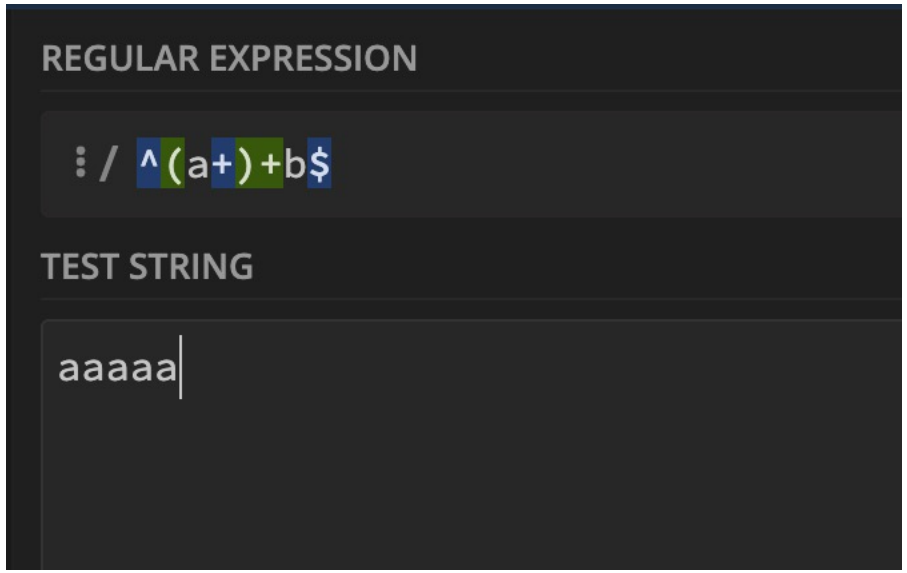

https://regex101.com/

実行の様子を確認する

- 正常2

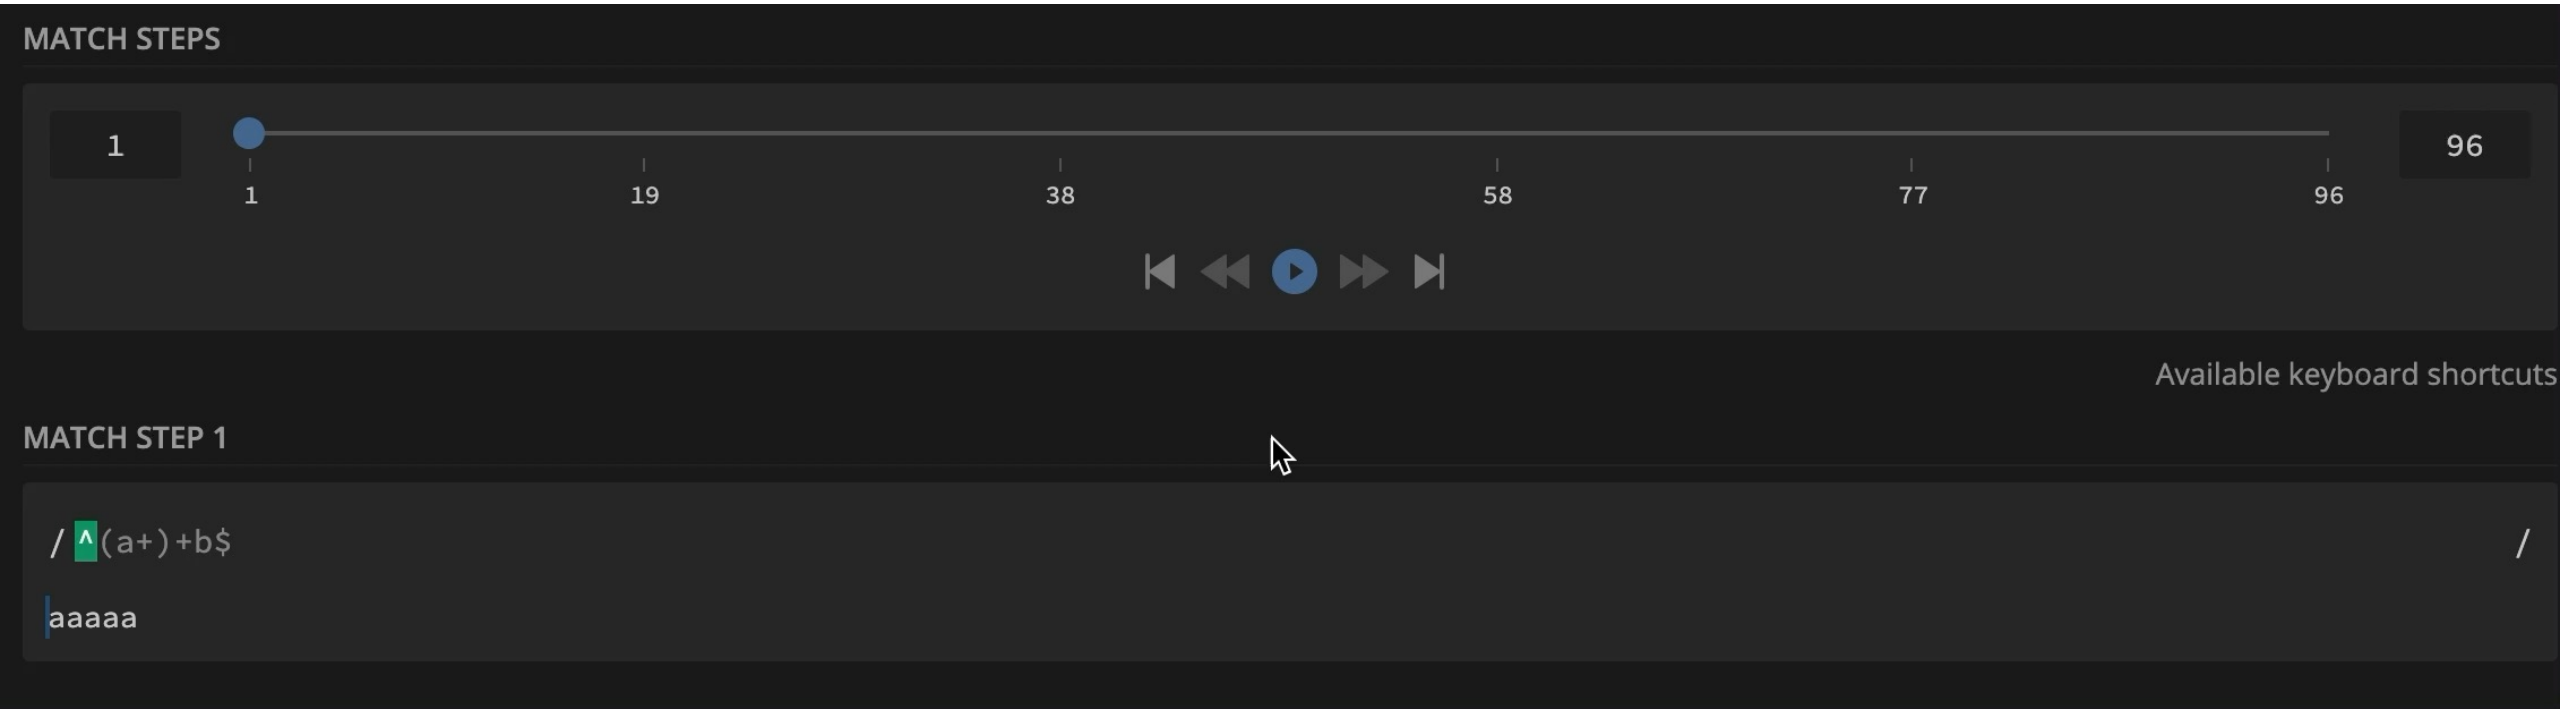

https://regex101.com/

実行の様子を確認する

- 異常

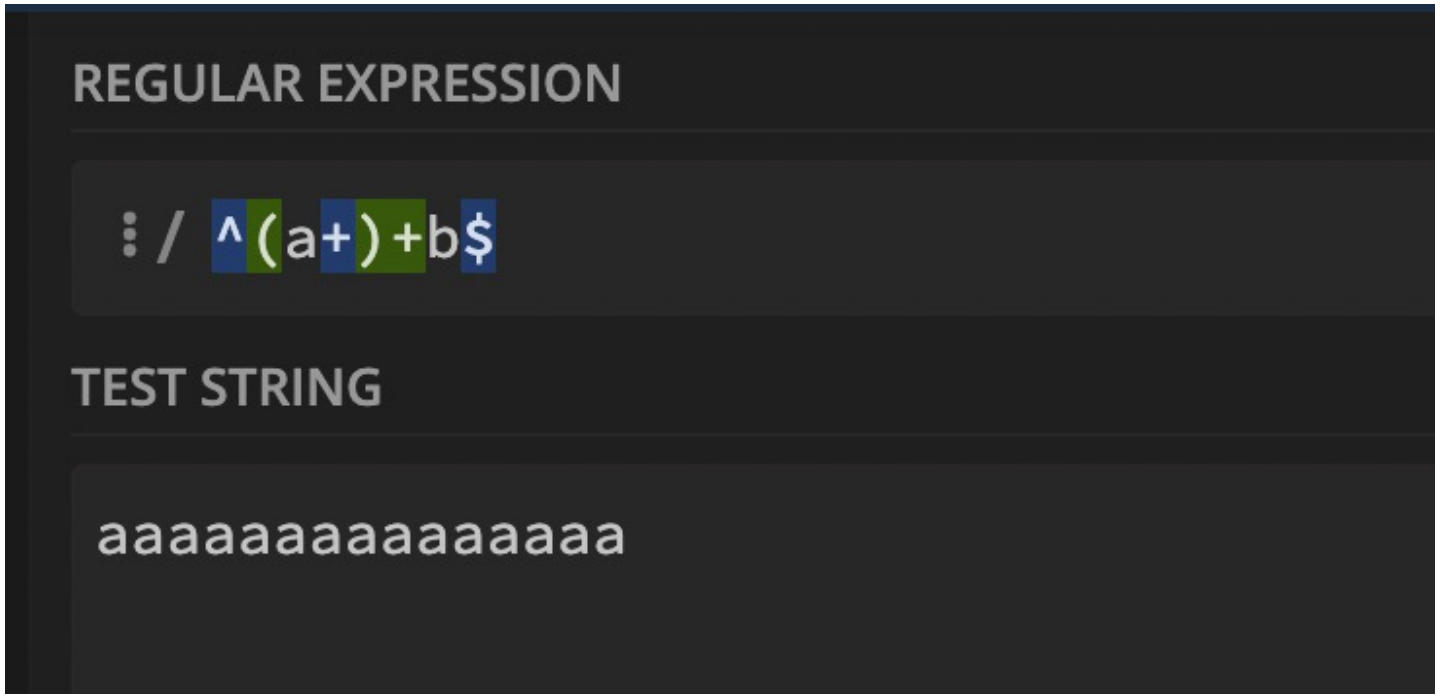

https://regex101.com/

実行の様子を確認する

- 異常

最初の200手↓

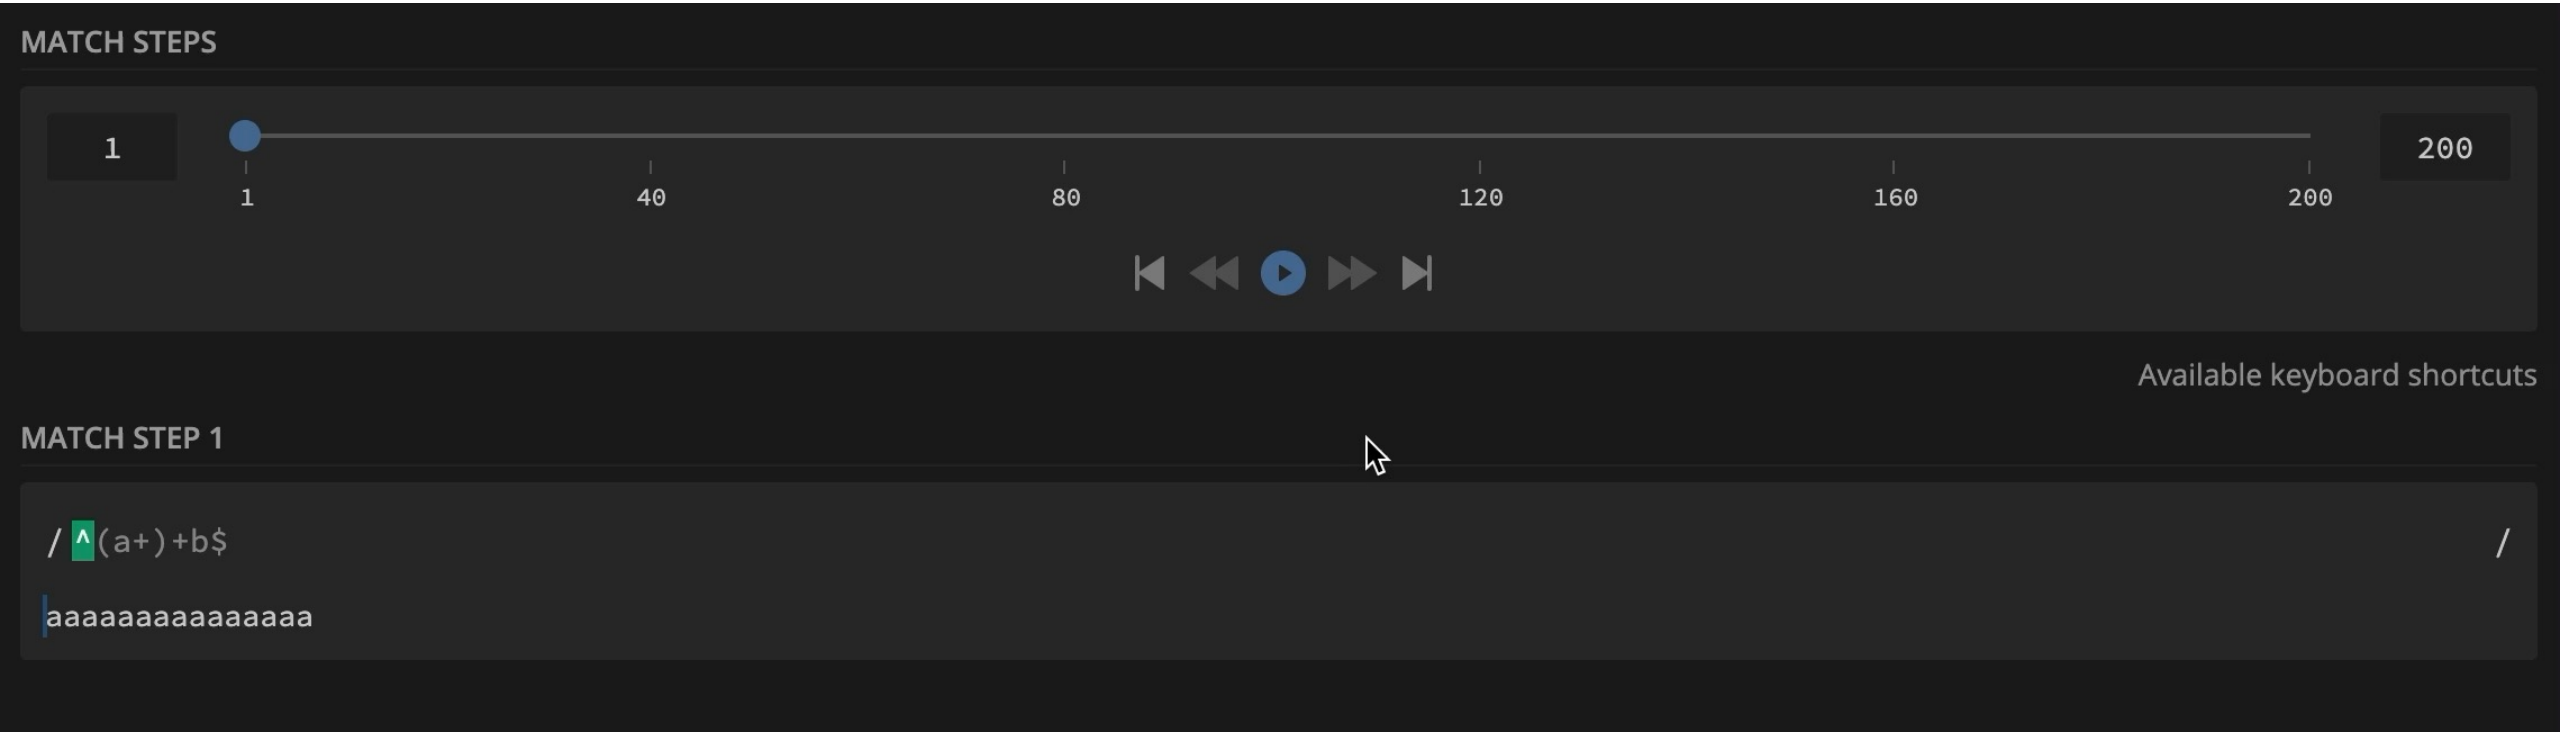

https://regex101.com/

実行の様子を確認する

- aの個数が増えるとステップ数はどうなるのか

aの個数	ステップ数
3	24
5	96
10	3072
15	98304
20	119987

なぜこうなるのか

- 正規表現はオートマトンによって文字列を評価しています
- オートマトンとは？ (↓こんな感じの)

$\Sigma = \{0,1\}$　：サイコロの目一覧

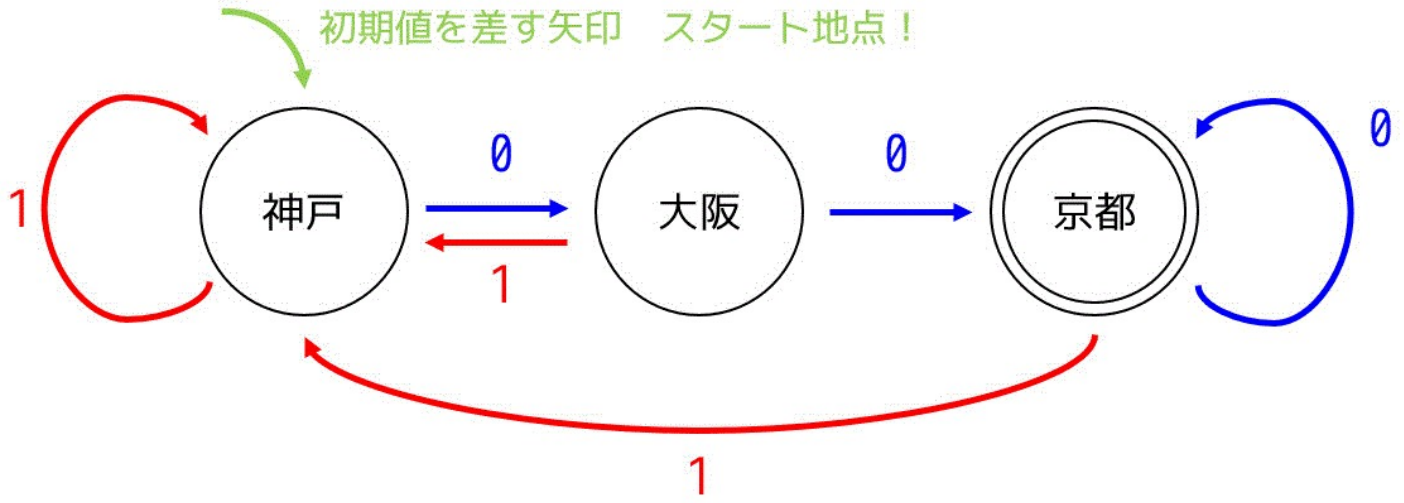

https://www.momoyama-usagi.com/entry/info/automaton01

なぜこうなるのか

- 正規表現はオートマトンによって文字列を評価しています
- あの正規表現のオートマトンは？

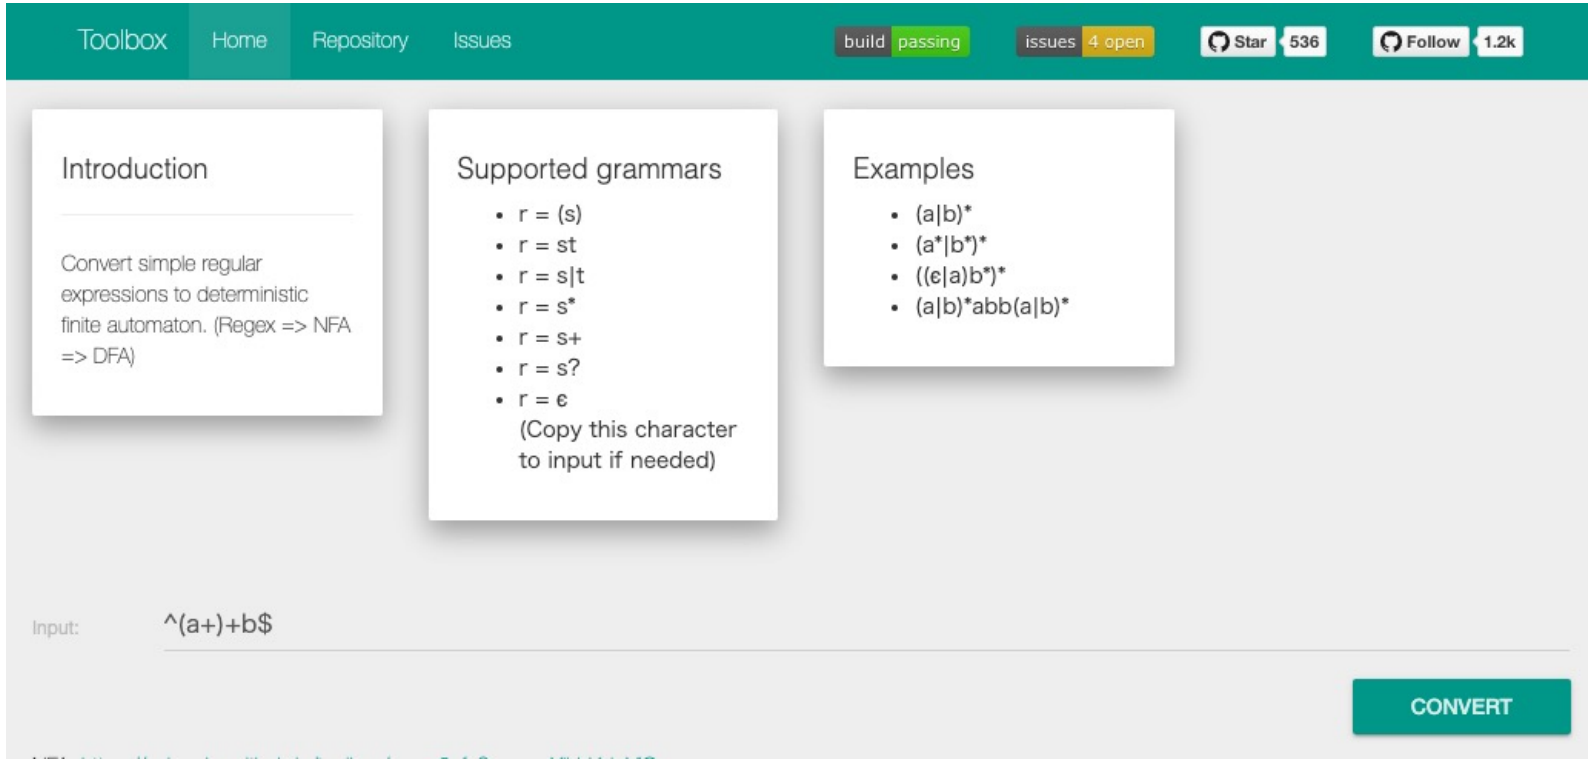

https://cyberzhg.github.io/toolbox/nfa2dfa

なぜこうなるのか

- 正規表現はオートマトンによって文字列を評価しています
- あの正規表現のオートマトンは？

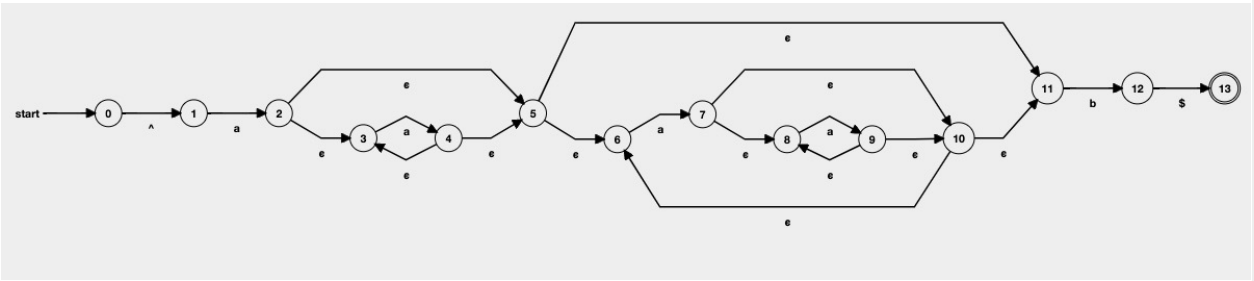

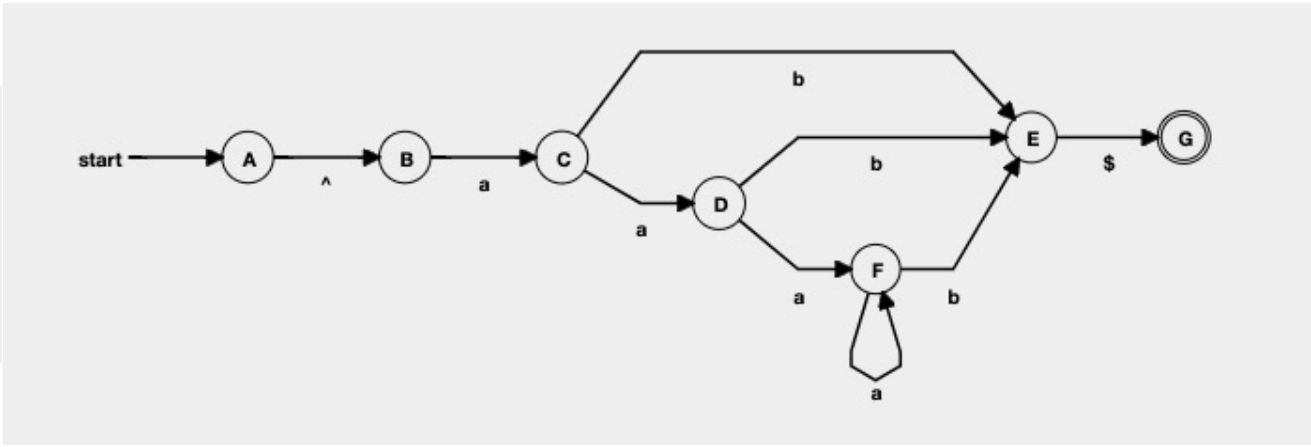

Pythonのreはこっち

非決定性オートマトン(NFA)

決定性オートマトン(DFA)

https://cyberzhg.github.io/toolbox/nfa2dfa?regex=XihhKykrYiQ=
https://cyberzhg.github.io/toolbox/regex2nfa?regex=XihhKykrYiQ=

なぜこうなるのか

- 正規表現はオートマトンによって文字列を評価しています
- あの正規表現のオートマトンは？

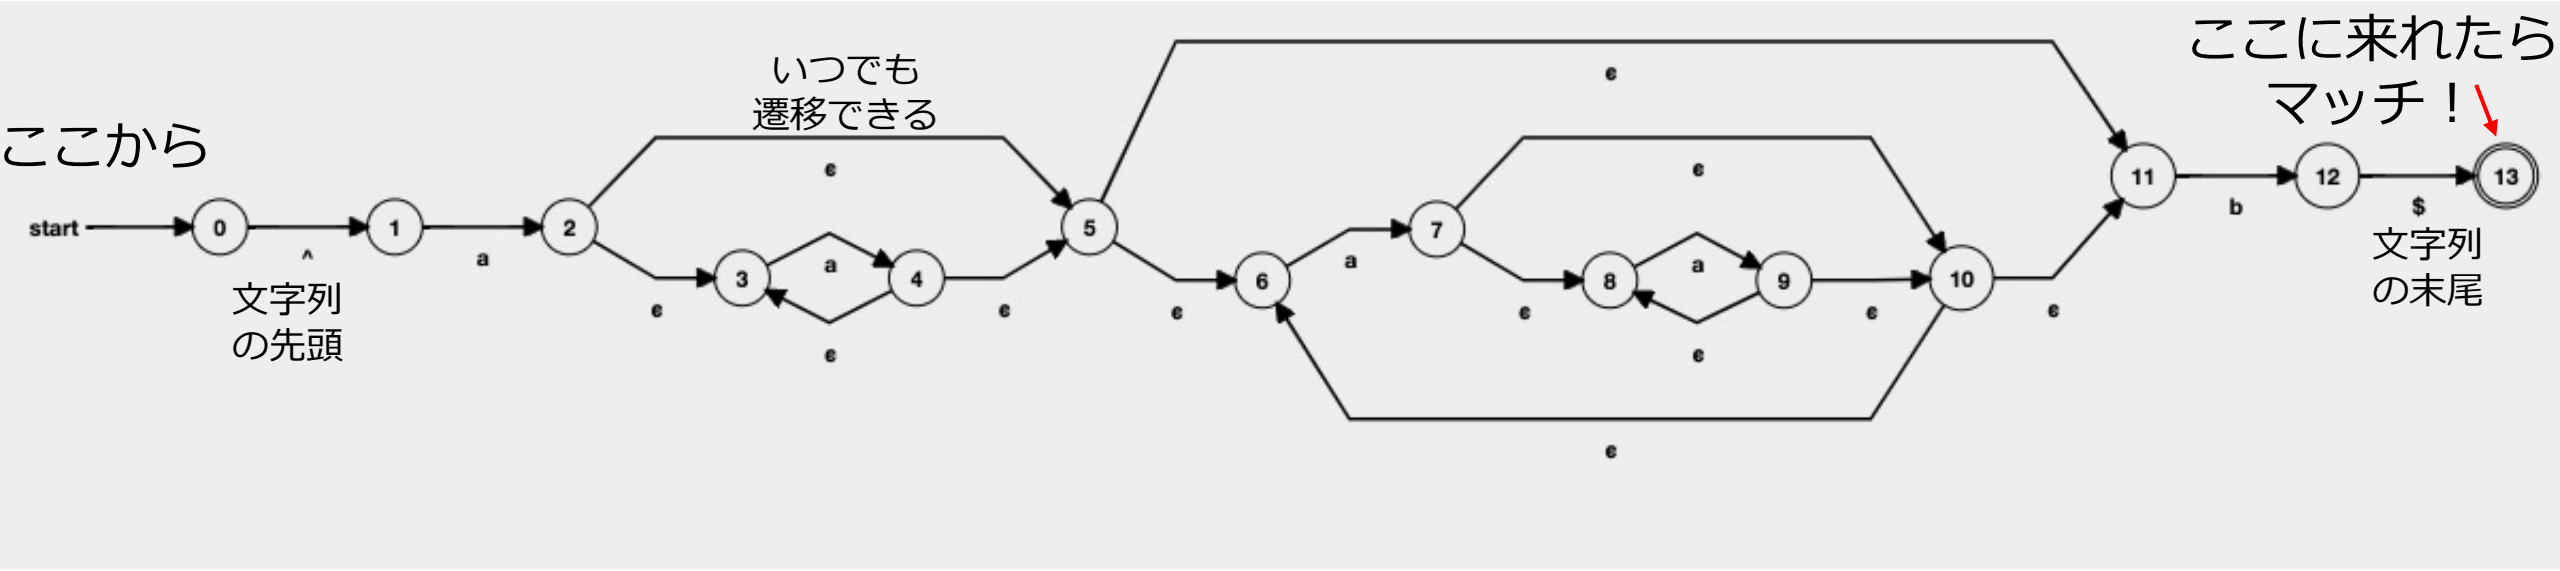

https://cyberzhg.github.io/toolbox/regex2nfa?regex=XihhKykrYiQ=

なぜこうなるのか

- 正規表現：^(a+)+b$
- 入力: aaaaa

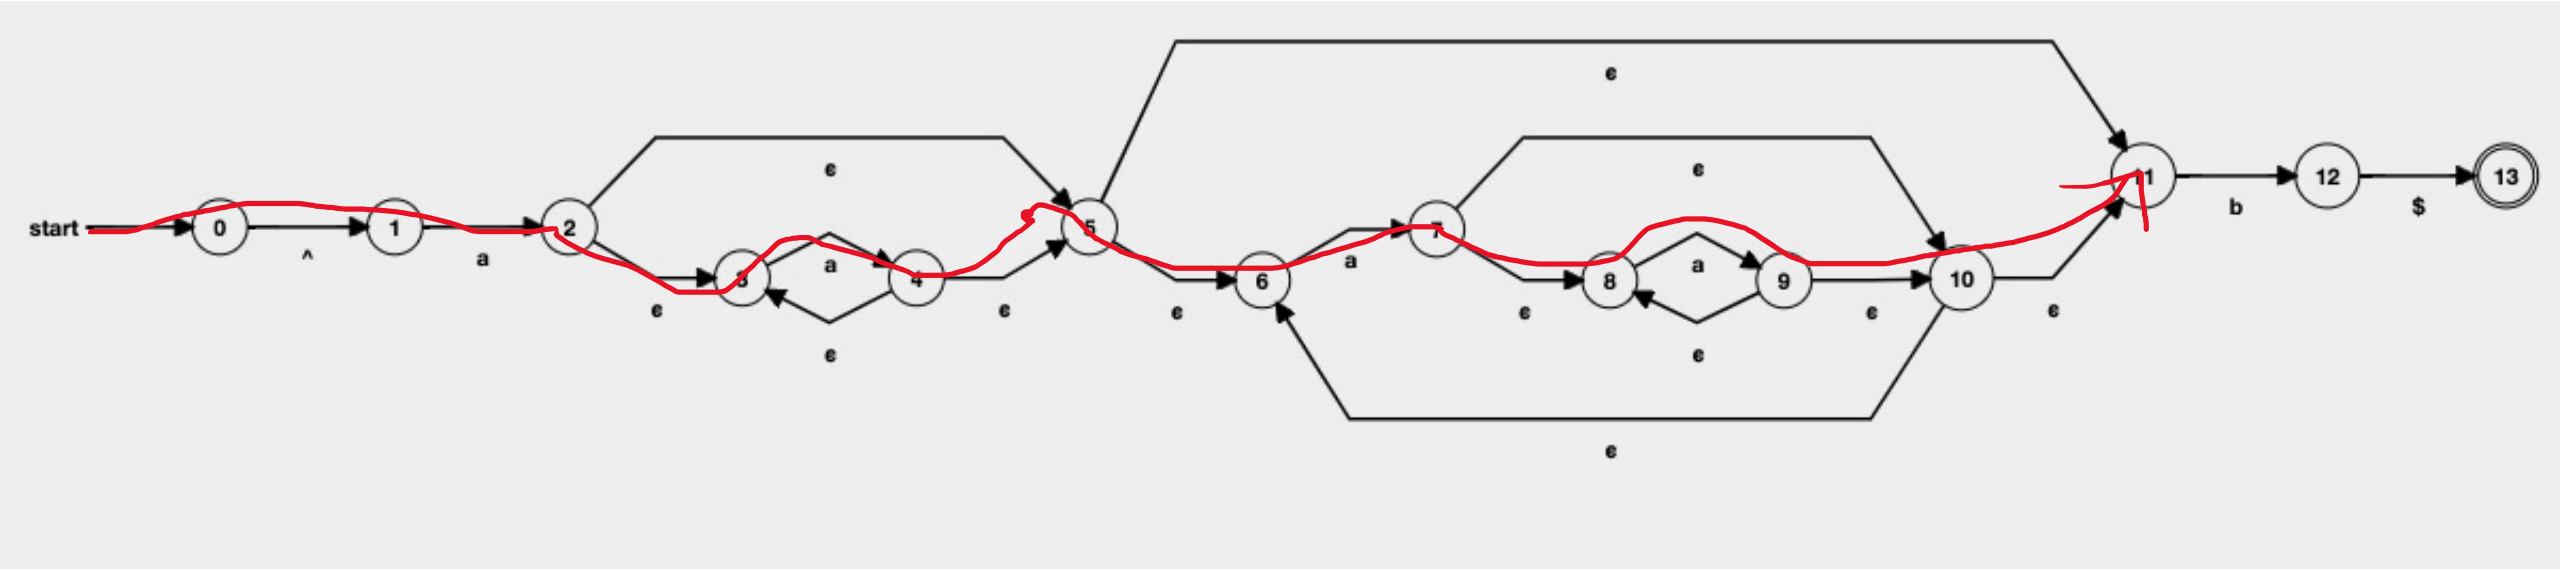

https://cyberzhg.github.io/toolbox/regex2nfa?regex=XihhKykrYiQ=

なぜこうなるのか

- 正規表現：^(a+)+b$
- 入力: aaaaa

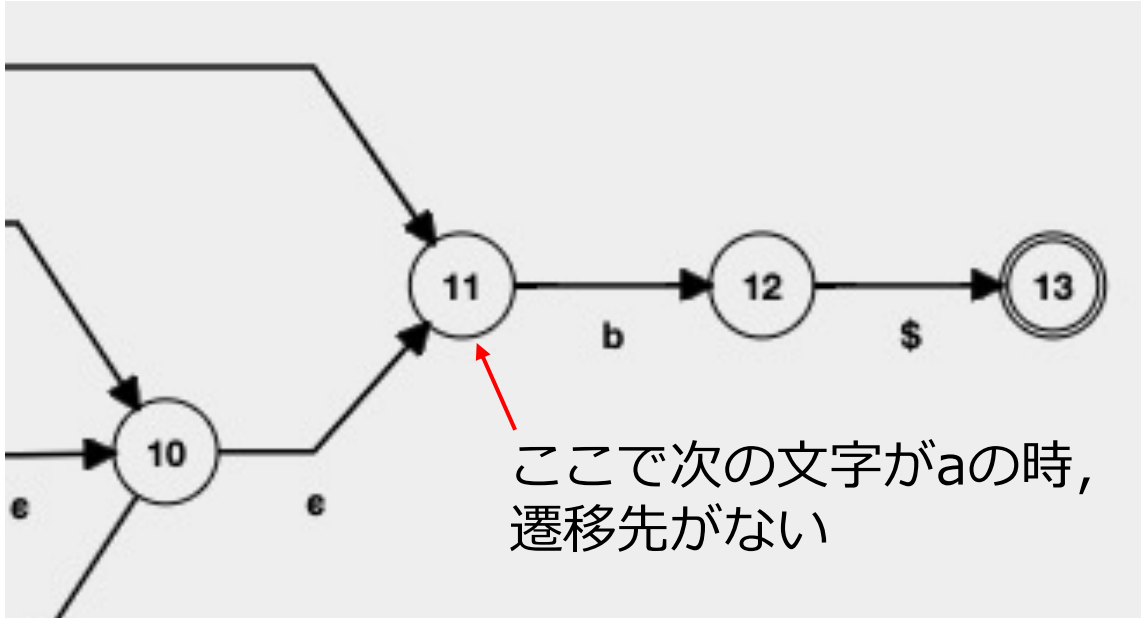

遷移先がないとき，前にミスったのかなって考える
→ちょっと戻る

https://cyberzhg.github.io/toolbox/regex2nfa?regex=XihhKykrYiQ=

なぜこうなるのか

- 正規表現：^(a+)+b$
- 入力: aaaaa

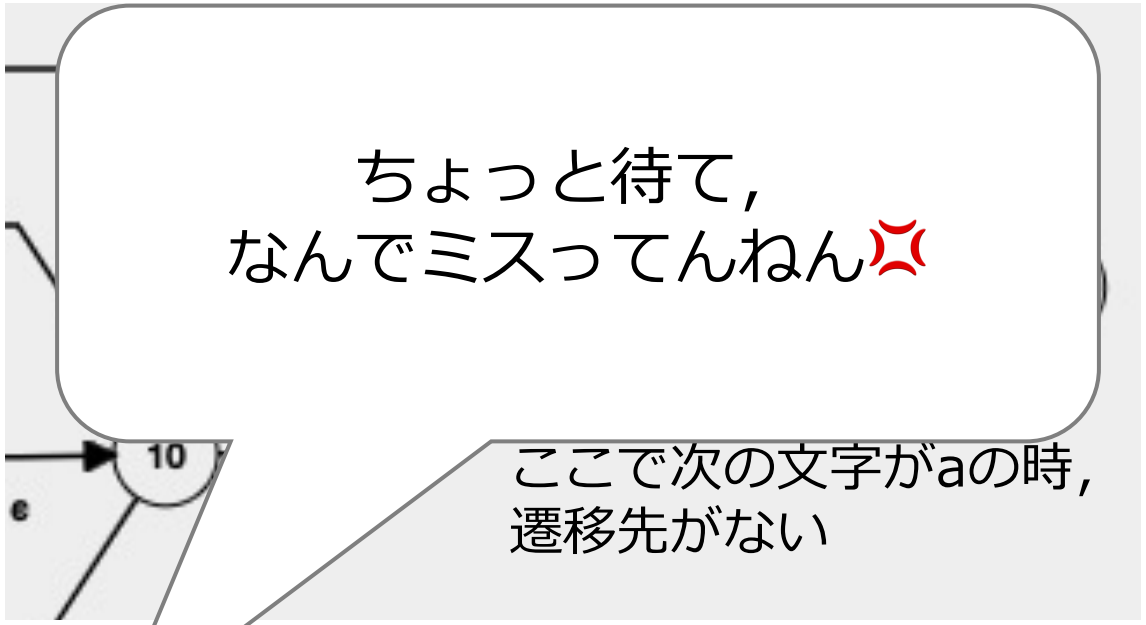

遷移先がないとき，前にミスったのかなって考える
→ちょっと戻る

https://cyberzhg.github.io/toolbox/regex2nfa?regex=XihhKykrYiQ=

なぜこうなるのか

- 正規表現：^(a+)+b$
- 入力: aaaaaa

テーマ: +の適用範囲が難しい
問題:(a+)と+はどの部分を指しますか？

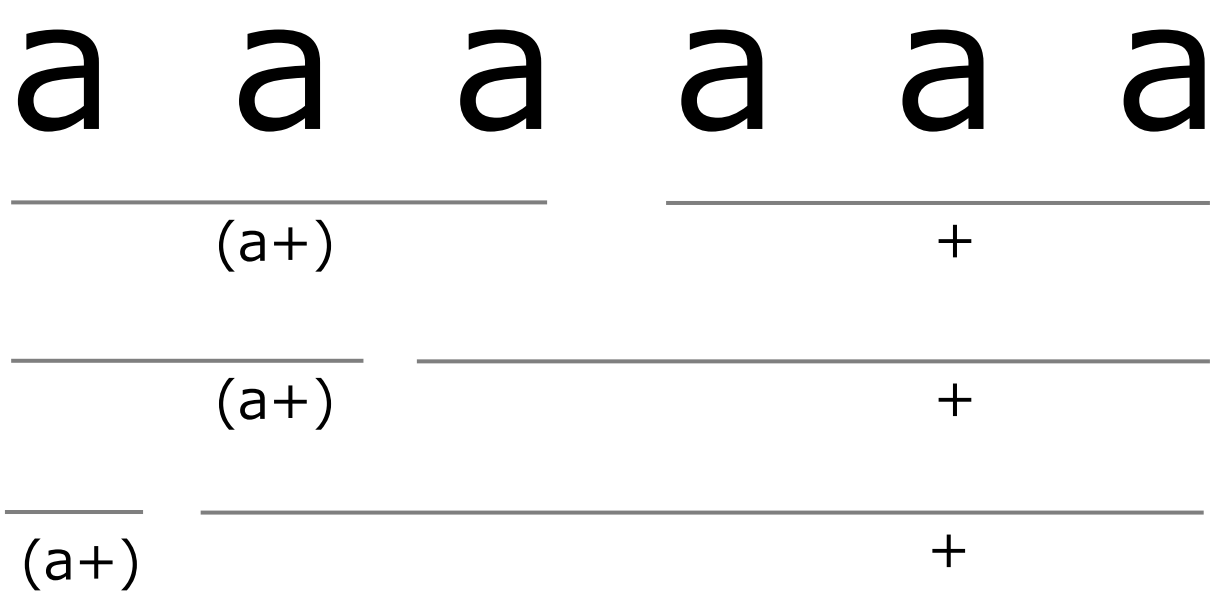

→いっぱいあって難しいから，とりあえずいっぱい進んで，
ダメだったら少し戻る方針

なぜこうなるのか

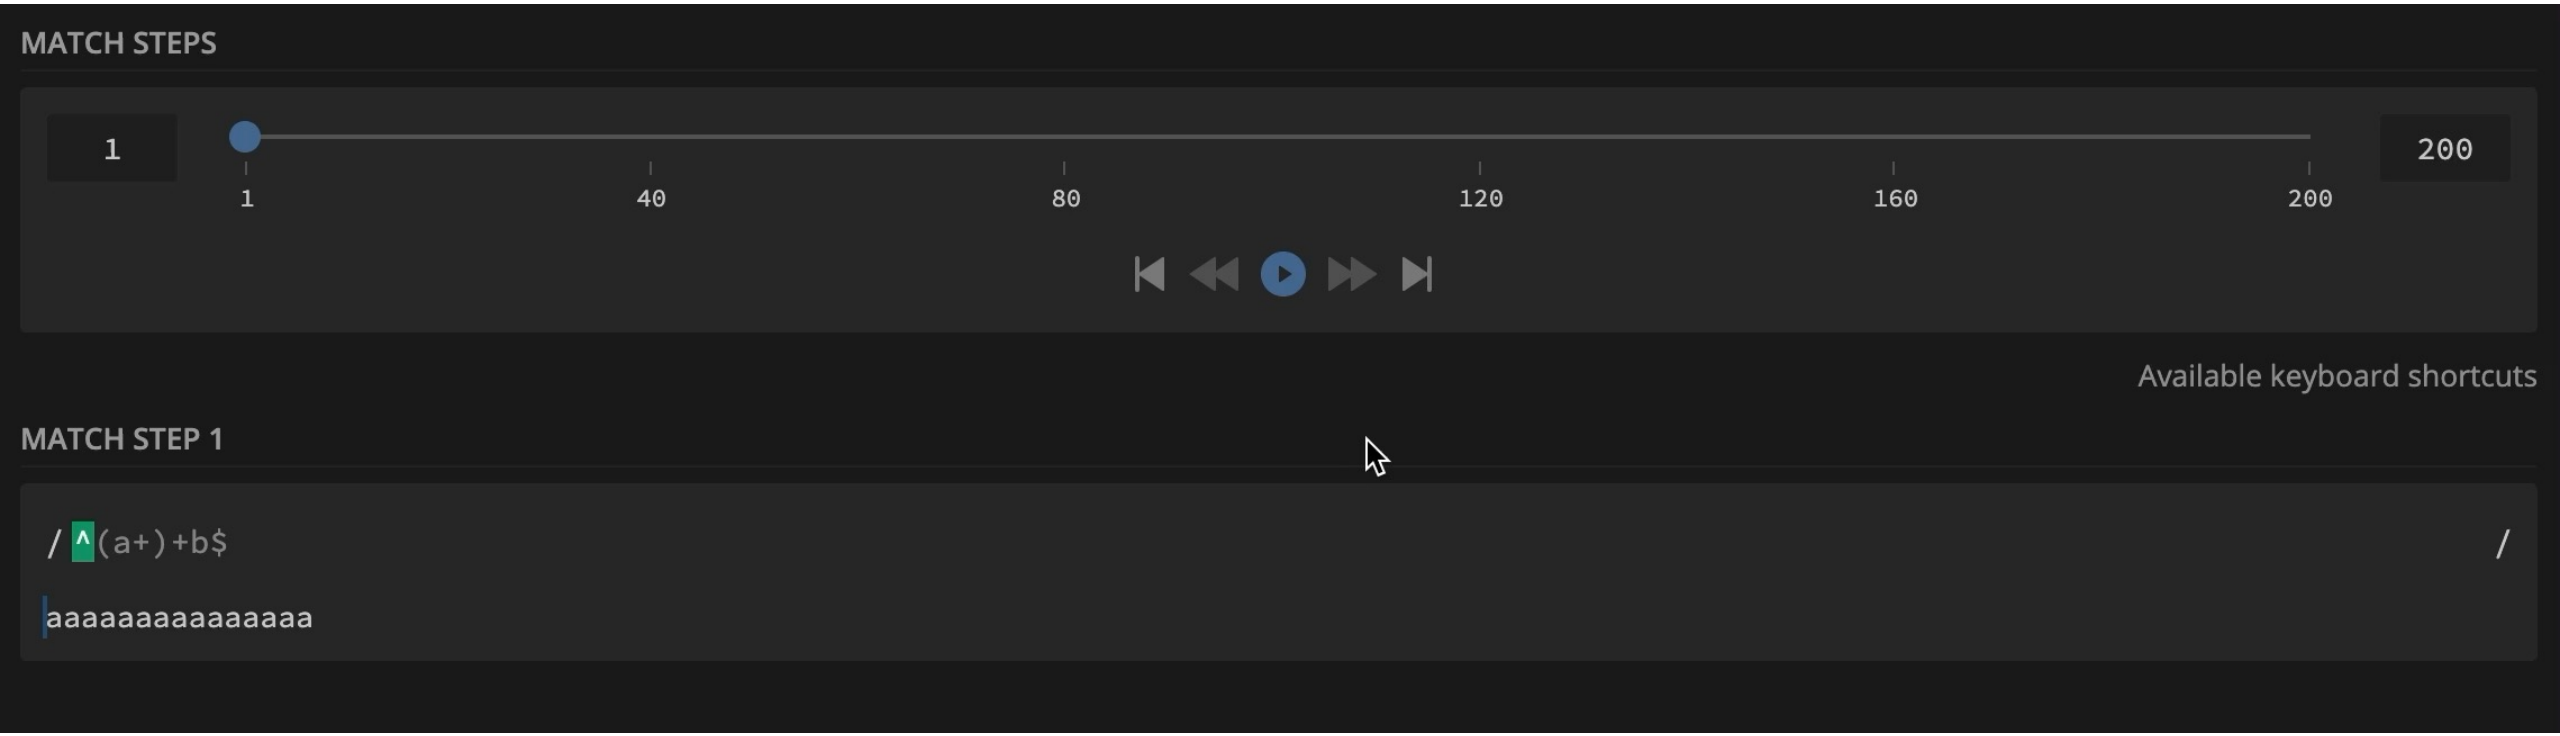

→とりあえずいっぱい進んで，ダメだったら少し戻る方針

対策

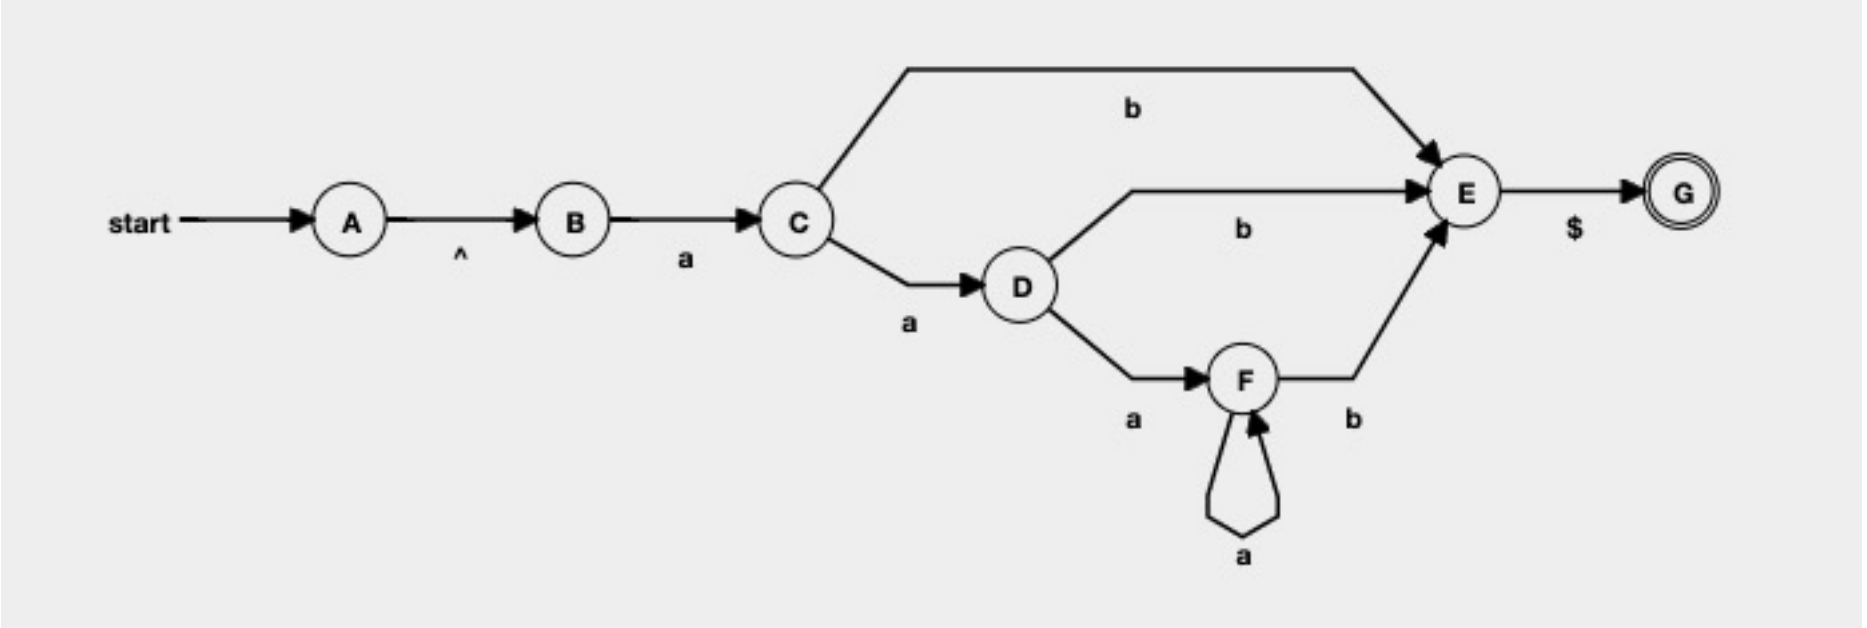

決定性オートマトン(DFA)が使われるライブラリを使う

https://cyberzhg.github.io/toolbox/nfa2dfa?regex=XihhKykrYiQ=

対策

対策

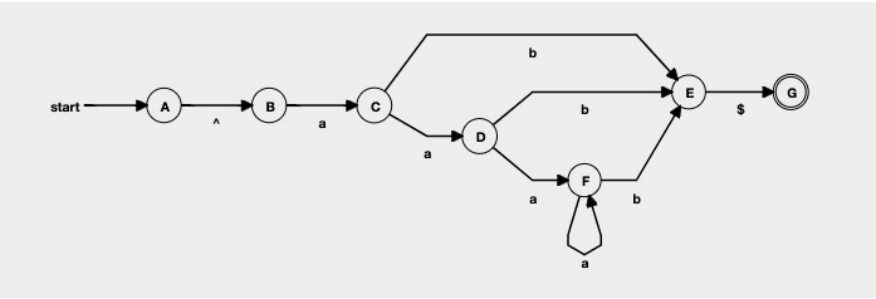

pyre2 0.3.6

```
pip install pyre2
```

決定性オートマトン(DFA)
が使われるライブラリ

予防

- 正規表現はできるだけコピペ
  - メアド，電話番号などは拾える
  - ユーザの入力は信用しない
- 繰り返し表現はできるだけ使わない
  - +や*
- 入力文字数制限
  - 最大30文字までなど
- タイムアウトを設定
  - 実行時間は最大10秒など